

基于知识图谱和大模型的车辆决策系统

吴绍斌^{1,2}, 姜皓舰¹, 黄凯宇¹, 黄宇¹, 褚云峰¹

(1. 北京理工大学 机械与车辆学院, 北京 100081; 2. 北京理工大学 郑州智能科技研究院, 河南, 郑州 450046)

摘要: 车辆在复杂环境中的决策是无人驾驶技术的关键环节. 针对传统决策方法泛化性差、环境适应能力不足等问题, 本文构建了一种“知识图谱+大语言模型 (LLM)”协同的智能决策框架. 系统首先借助 CARLA 仿真平台采集车辆及环境的动态数据, 并与专家预定义的静态知识图谱融合, 形成可持续更新的综合知识图谱, 统一存储于图数据库 Neo4j 中. 随后, 通过 Cypher 规则推理快速生成先验决策候选; 在此基础上, 引入 LLM 进行知识增强检索与链式思维推理, 实现对策略的优化与解释生成. 试验结果表明: 在仿真城市环境下, 知识图谱决策的综合决策准确率达 95% 以上, 平均响应时延小于 60 ms; 在越野实车实验中, 与仅使用知识图谱或仅使用 LLM 的基线相比, 所提方法准确率有所提升. 验证了知识图谱结构化知识与 LLM 推理能力的互补优势, 为无人车辆高可靠决策提供了一条可行路径.

关键词: 知识图谱; 大语言模型 (LLM); CARLA 仿真; 无人车辆; 智能决策

中图分类号: TP391

文献标志码: A

文章编号: 1001-0645(2026)01-0029-09

DOI: 10.15918/j.tbit1001-0645.2025.076

Vehicle Decision-Making System Based on Knowledge Graph and Large Model

WU Shaobin^{1,2}, JIANG Haojian¹, HUANG Kaiyu¹, HUANG Yu¹, CHU Yunfeng¹

(1. School of Mechanical Engineering, Beijing Institute of Technology, Beijing 100081, China; 2. Zhengzhou Academy of Intelligent Technology, Beijing Institute of Technology, Zhengzhou, Henan 450046, China)

Abstract: The decision-making of vehicles in complex environments is a critical aspect of autonomous driving technology. To address issues such as poor generalization and insufficient adaptability to dynamic environments in traditional decision-making methods, an intelligent decision-making framework that integrates knowledge graph and large language model (LLM) was constructed. The system first collected dynamic data on vehicles and their environment using the CARLA simulation platform, which was then combined with pre-defined static knowledge graphs to form a continuously updated comprehensive knowledge graph, uniformly stored in the Neo4j database. Subsequently, Cypher rule inference quickly generated prior decision candidates; on this basis, LLM was introduced for knowledge-enhanced retrieval and chain-of-thought reasoning, achieving optimization and explanation of strategies. Experimental results show that in simulated urban environments, the comprehensive decision accuracy of knowledge graph-based decision-making was over 95%, with an average response time of less than 60 ms; in off-road vehicle experiments, compared to baselines using only knowledge graphs or only LLM, the proposed method showed improved accuracy. This validates the complementary advantages of structured knowledge from knowledge graphs and LLM inference capabilities, providing a viable path for highly reliable decision-making in autonomous vehicles.

Key words: knowledge graph; LLM; CARLA simulation; unmanned vehicle; intelligent decision-making

收稿日期: 2025-04-30

基金项目: QDK 环境 XXX 三维运动规划资助项目 (ZW040204); 国家科技重大专项基金资助项目 (2022ZD0115503)

作者简介: 吴绍斌 (1972—), 男, 博士, 副教授, E-mail: shaobinwu@bit.edu.cn.

近年来,无人驾驶技术作为人工智能技术的发展热点之一,得到学术界、工业界的高度关注.无人驾驶车辆在行驶过程中,存在环境感知、障碍辨识、路径规划、行为预测与决策控制等一系列需要进行数据处理的任务,这些任务的数据特征往往是动态的、具有海量且复杂的关联关系及不确定性.其中车辆行为决策在自动驾驶系统中占据着核心地位,行为决策的目标主要是保证车辆可以像人类一样产生安全的驾驶行为,满足车辆安全性能、遵守交通法规等原则.传统基于规则的决策系统逻辑严谨,易实现,但是在复杂的、动态的环境中存在显著不足,难以高效处理突发及不可知的状况.

知识图谱和大语言模型(LLM)作为人工智能领域的重要研究方向,逐渐展现出在智能决策系统中的巨大潜力.知识图谱(knowledge graph, KG)技术,基于语义化的知识组织方法与推理能力,近年来开始应用于无人驾驶中^[1].知识图谱通过语义化方式组织实体关系,能有效解决传统决策系统推理能力弱、语义关联性差的问题,提升系统智能化水平.大语言模型凭借出色的语言理解与生成能力,可完成复杂推理任务.两者结合能充分发挥结构化知识与语言推理的互补优势,为无人驾驶提供更智能可靠的决策支持.

知识图谱概念最早于2012年由谷歌提出,其初衷在于实现搜索结果的语义关联,提升搜索的智能化水平^[2].知识图谱通过实体、关系、属性的三元组结构形式,显式地表达知识间的语义关系,并已在多个领域取得广泛应用,包括自然语言处理、智能问答系统、推荐系统等.近年来,知识图谱逐渐被应用于无人驾驶领域^[3].IEEE RAS 提出标准化本体模型,以服务、感知、资源、平台与任务为中心构建无人车辆领域的知识表达. KnowRob 项目则开发了针对机器人动作、环境、对象的语义化知识库,为机器人自主决策提供推理支持^[4].然而,这些知识图谱普遍关注静态数据表达,缺乏对动态信息的实时捕捉与更新.

大语言模型(LLM)已成为人工智能领域的核心技术,以 GPT、PaLM、LLaMA 等为代表的模型在自然语言处理、文本生成与问答等任务中表现出强大能力^[5].这些模型广泛应用于搜索、客服与内容创作等领域.然而,大模型在行业知识融合、跨领域理解与训练成本等方面仍存在局限.因此,如何结合知识图谱等结构化知识以增强其专业性与推理能力,已成为当前研究的重点方向.

综上所述,知识图谱与大语言模型在智能决策系统中的深度融合尚处探索阶段.知识图谱擅长结构化表达与逻辑推理,可提升系统的可解释性与知识广度;大模型则具备强大的语言理解与生成能力,支持灵活推理^[6].二者结合可增强知识约束与语义理解,提升复杂环境下的泛化能力与决策精度.然而,当前国内外研究仍缺乏有效融合机制,尤其在动态交通场景中,如何实现两者在推理与行为规划上的协同,是亟待解决的关键问题.

本文针对车辆行为决策提出一种融合知识图谱与大模型的智能车辆决策方法.首先,通过 CARLA 平台采集无人车辆在动态交通环境中的运行数据,并构建动态知识图谱;其次,将实时动态数据与专家定义的静态知识图谱进行语义融合,形成可推理的综合知识图谱;随后,基于图数据库 Neo4j 与 Cypher 语言进行规则推理,实现初步决策生成;最后,引入大语言模型,综合知识图谱与推理结果生成最终的高质量决策指令,提升系统的智能化水平与泛化能力.

1 决策系统整体框架

针对传统决策系统知识表达不足和推理泛化能力受限这一问题,通过构建知识图谱能够有效应对传统决策系统知识不足的问题,通过引入大模型则能很好地提高系统的推理泛化能力.

图1为车辆智能决策系统总体架构示意图.本系统由大语言模型驱动的任务推理模块、知识图谱模块,以及感知、决策生成、执行等子模块组成.箭头表示数据流和交互:高层任务指令经由 LLM 解析,知识图谱提供环境知识与规则约束,决策模块生成具体的行为决策指令,执行模块控制车辆,并通过感知模块反馈更新环境信息,实现闭环决策.如图1所示本系统架构包含以下主要模块:

① 感知模块:负责采集无人车辆的传感器数据,实时更新地图障碍物、敌方位置、天气等动态要素至知识图谱,提供决策所需的环境信息,并持续反馈环境变化,实现感知与响应的闭环.

② 推理模块(LLM):以 Qwen2.5 大语言模型为核心,解析自然语言任务指令,完成任务理解与分解,并与知识图谱交互提取领域知识,细化任务步骤,生成结构化的任务计划,支持下游路径规划与执行.

③ 决策生成模块:整合 LLM 推理结果与知识图谱检索信息,通过 Cypher 查询和 Prompt 构造,利

用大模型多轮推理能力生成详尽的决策方案,并输出至执行模块。

④ 执行模块: 执行决策方案, 完成车辆控制与

任务动作. 与感知模块协同运行, 获取状态反馈并监控执行进展, 若遇异常可请求重新推理, 构建自适应的闭环控制机制。




图 1 系统架构主要模块

Fig. 1 Main modules of system architecture

2 知识图谱概念与架构

为有效应对传统决策系统知识表达不足这一问题, 本节通过构建知识图谱体系架构以提高知识表达能力。

2.1 知识图谱基本概念与构建方法

知识图谱的基本构件单位是实体 (Entity)、关系 (Relation) 和属性 (Attribute)。具体来说, 知识图谱将知识以三元组的表示方式, 表示为 (实体-关系-实体) 或 (实体-属性-值)^[7], 以图数据库的方式存储下来, 具备网络化、结构化等特征, 便于高效地查询和推理。

知识图谱构建方法分为 3 种: 自顶向下、自底向上和混合方法。自顶向下方法由专家定义模式层并添加实例, 适用于知识领域有限、数据量小的场景; 自底向上方法从文本中抽取实体、属性、关系, 并进行知识融合, 适合大数据、高自动化场景。混合方法结合了前 2 种方法, 既利用专家知识保证结构清晰, 又通过自动化工具处理大量数据。

本研究采用的混合构建方法如图 2 所示, 利用领域专家知识定义模式层结构, 再从 CARLA 仿真平

台实时采集动态数据, 以自底向上的方式自动提取动态知识, 并结合静态知识进行融合, 形成动态与静态相结合的综合知识图谱^[8]。




图 2 知识图谱构建框架

Fig. 2 Framework of knowledge graph construction

2.2 知识图谱体系架构

基于知识图谱的车辆决策系统主要包含模式层和数据层 2 大核心部分。

① 模式层定义领域基本概念、实体和关系类型, 分为静态和动态 2 部分。静态模式层描述不变的环

境知识,如地形、天气、道路和障碍物;动态模式层表示车辆运行中的实时变化,如位置、速度和周围车辆态势。

② 数据层基于 CARLA 仿真平台的实时数据,以三元组形式存储。它包含静态知识和动态数据,使用 Neo4j 图数据库进行实时存储更新,支持高效查询和推理。

知识图谱的存储推理是实现智能决策的前提。存储分析知识图用的图数据库工具 Neo4j,它拥有图形结构数据的管理能力^[9]。本研究采用 Neo4j 保存知识图谱,用 Cypher 语言创建、查询、导出知识图谱。Neo4j 高效地存储处理图谱结构的数据,支持对节点的操作和关系的查询。Cypher 查询语言实现对知识图谱的推理功能,通过对节点之间关系、节点之间的属性的多条件组合查询,实现对车辆决策相关数据的实时分析推理决策结果输出。

2.3 知识图谱模式层建模

Protégé 支持用户自定义界面,具有可扩展的结构,用户可以根据自身需求添加所需的功能模块^[10]。综合考虑本文的实际情况,采用 Protégé 建模工具实现本体的构建工作。首先构建无人车辆知识图谱模式层本体,将其分为天气状况、障碍物、无人车辆、交通标识、机动模式,然后分别定义每一类知识的实体和关系,通过对车辆类型、动作、任务、任务环境(含天气、地形、地表材质)等概念及关系的形式化定义,实现了该领域知识的结构化组织与关联。

3 基于 CARLA 仿真的数据采集与动态知识图谱构建

为了丰富知识图谱的构建,本节基于 CARLA 仿真来实时采集构建动态知识图谱所需数据,并构建出动态知识图谱。

3.1 动态数据采集与处理

CARLA 是一个开源的自动驾驶仿真平台,用于研究、开发和验证。它具备丰富的虚拟城市环境、传感器仿真和实时数据分析。平台由服务器端和客户端组成,服务器端构建仿真环境,客户端 API 定义车辆行为和实时交互。

该平台实时提供车辆运动、环境感知和传感器数据,数据种类多、精度高、时效性好,有助于进行数据的采集以及分析。

数据采集方式:利用客户端 API 操控车辆在给

定场景中行驶,同时实时采集车辆速度、位置、姿态、传感器数据等车辆状态信息,并同步标记时间戳,即保证数据的及时性和有效性。

CARLA 平台上原始数据需要经过数据预处理才能提升其数据质量与适配性,具体所需要获取的数据与数据预处理方式如下:

① 静态环境要素包括道路结构、建筑物分布及固定障碍物。通过 CARLA 内置的语义分割接口,系统可识别场景中各类静态实体的类别与位置信息。为提高数据实用性,障碍物坐标由绝对坐标系转换为相对本车的极坐标系(方向与距离),并设定 50 m 的有效感知范围。此转换降低了后续知识图谱构建中空间推理的复杂度。

② 实时交通信息包括红绿灯、交通标志及动态障碍物(其他车辆、行人)。实时数据和时间戳同步记录,确保数据的时序性。

③ 无人车的决策行为(加速、制动、转向等)通过解析油门与转向控制信号实现。例如,油门开度大于阈值时标记为“加速”,方向盘转角绝对值超过 10° 时标记为“转向”。此类数据与感知信息关联后,可构建“场景-动作”映射关系,为知识图谱提供样本。

3.2 动态知识图谱构建方法

在数据采集阶段完成后,会对采集的数据进行细致处理,包括去掉冗余的数据以及统一数据的结构。经过数据处理之后,将数据导入到知识图谱图数据库中,以便进行更深入的处理和分析工作。该工作涉及到从采集的数据中提取有价值的信息,并将其转化为知识图谱中的节点和边。知识图谱的输入处理步骤具体包括以下几个方面:

① 实体抽取:从经过预处理的数据中识别并提取出各种实体信息(例如车辆、障碍物、交通标志等),然后将这些实体信息对应地映射到知识图谱的节点上。

VehicleState 节点:用以存储每个时刻的自车状态信息。节点的核心属性包括当前帧编号、当前速度、交通信号灯颜色以及该时刻的决策动作等。

OtherVehicle 节点:用以记录自车周围他车的位置及距离信息,每个节点表示一辆他车的相对状态,例如方向及距离。

Scenario 节点:用以明确当前数据归属于哪种场景,用于不同场景数据的区分和管理。

② 关系抽取:提取实体之间的各种关系,并将

这些关系信息映射到知识图谱的边。

HAS_OTHER 关系: 从 VehicleState 节点指向 OtherVehicle 节点, 表示在该状态下存在其他车辆, 关系上附带车辆相对方向和距离的具体属性。

BELONGS_TO 关系: 从 VehicleState 节点指向 Scenario 节点, 明确每个车辆状态节点隶属于某个特定的场景数据集。

③ 属性抽取: 此步骤专注于从数据中提取实体的详细属性信息(车辆的速度、障碍物的具体位置、交通标志的类型等), 并将这些属性信息映射到知识图谱中相应节点的属性上。

构建动态知识图谱涉及定义动态实体, 如自行车、周边车辆、障碍物和环境节点, 并赋予它们动态属性, 如位置和速度。根据实时交互, 动态生成或更新节点间关系, 反映交通场景中实体交互。使用 Cypher 查询语言和事件触发机制, 实时更新节点属性, 更新频率采用分层策略: 常规状态如位置、速度等每 1~5 s 批量更新一次, 以降低数据库负载; 而急刹、碰撞、偏离路线等关键事件则采用实时触发机制, 确保毫秒级响应。

4 融合大模型与知识图谱的决策系统

4.1 模块设计

4.1.1 知识增强模块

知识增强实现思路: 系统首先解析输入的任务指令或环境描述, 从中抽取出关键实体和关系。随后, 在 Neo4j 知识图谱中通过 Cypher 查询检索与这些实体相关的路径, 利用知识图谱查询语义最接近的实体集合。Neo4j 强大的图查询能力确保能够高效地获取信息片段, 如敌方单位→装备类型→性能参数等知识链条。得到相关知识子图后, 将其转换为 LLM 可理解的表示形式, 常用方式包括生成结构化文本摘要(例如三元组列表)。在决策推理时, LLM 将任务上下文与该知识进行融合, 生成考虑了背景知识的回答和行动方案。

4.1.2 知识补全机制

大模型通过自然语言查询语句, 理解并推理知识图谱中的缺失信息。利用自然语言推理能力, 生成缺失知识的候选实体或关系^[11]。针对知识图谱中部分缺失信息, 系统设计关系补全模板, 引导大模型补全知识图谱中的缺失三元组信息。为提高补全知识的正确率, 补全知识的时候需满足所设置的条件, 根

据新三元组的距离和阈值进行比较来判断这个新三元组的正确性。补全流程图如图 3 所示。




图3 三元组缺失补全流程图

Fig. 3 Flowchart of whole process of triplet deletion and supplementation

本文提出一种基于语义类比、图谱结构回溯与大模型联想补全融合机制的三元组补全策略。该机制依据缺失类型, 分别设计 3 种补全路径, 并结合结构提示词模板, 调用大语言模型生成逻辑一致、上下文贴合的缺失信息, 从而实现图谱知识的动态自修复。整个流程由 4 个阶段构成: ① 缺失识别与类型判定; ② 结构模式匹配与候选生成; ③ Prompt 模板构建与大模型推理; ④ 补全结果筛选与结构注入。

4.1.3 泛化推理机制

泛化推理模块的重要特征是在需要时执行思维链推理, 即通过一系列中间推理步骤将若干知识片段串联起来得到最终结论。LLM 则擅长基于提示进行链式思维(chain-of-thought, CoT)推理, 逐步细化问题并得出答案。在本决策系统中采用类似思想: 当无人车辆面临复杂决策, 系统不求 LLM 一步给出答案, 而是让其产出推理链。第 1 层 Prompt 指导模型根据结构化三元组生成符合四段逻辑链条的中间推理文本; 第 2 层 Prompt 则将该推理链作为条件输入, 引导模型生成最终带操作指令或建议属性的结果输出。图 4 为系统的具体推理步骤。




图4 系统推理步骤

Fig. 4 System reasoning steps

4.2 决策实现

本文设计了一个决策系统软件, 基于 ollama 本地部署大模型平台, 搭载了 Qwen2.5 大模型, 并且与领域知识图谱结合, 创建了一个 RAG 车辆行为决策系统. 在实现基于领域知识图谱的无人平台决策系统过程中, 为保证在复杂战场环境下实时、高效地进行自主决策, 本文设计并实现了一个集成图数据库查询 (Neo4j) 与大模型推理 (LLM) 的决策模块. 该模块能根据感知到的环境态势信息和本体知识库进行实时推理, 进而做出可解释且具有针对性的行为决策方案.

系统首先将用户问题与知识图谱进行匹配, 检索出可能相关的三元组, 作为对决策问题的支持性信息. 随后将这些三元组与用户问题一起, 构建出适合大模型推理的 Prompt, 并调用函数与大模型交互, 实现思维链推理输出, 三元组在这里扮演了领域知识的角色, 大模型则依靠所提供的背景信息来进行推理并生成可解释的方案.

系统最终将大模型生成的推理链和答案拼装进行输出. 答案通常格式化为简单的行动指令标签, 从而实现后续程序的自动解析与执行.

5 实验验证与分析

本研究通过将越野作战场景与城市环境知识图谱纳入知识图谱数据库中形成统一的图数据库, 能有效应对一般城市环境与越野环境. 通过仿真和实车实验对本文提出的基于领域知识图谱的无人平台决策系统进行验证. 一是通过仿真实验, 验证所构建的知识图谱在城市环境下行为决策生成的正确性和有效性; 二是通过越野环境下的实车试验, 验证知识图谱与大模型结合方法的优越性与准确性.

5.1 仿真实验验证

仿真实验旨在验证本文构建的知识图谱在城市道路环境下进行无人平台决策生成的正确性和有效性, 评估决策系统在城市环境的表现.

5.1.1 实验环境

仿真采用 CARLA 仿真平台, 搭建典型城市环境

模拟场景. 使用 CARLA 仿真平台进行决策系统的实验验证. 仿真实验环境使用 Ubuntu 20.04 操作系统, 搭载 Intel Core i5 CPU、16 GB 内存以及 Nvidia GPU. 实验环境可以满足实时数据处理和渲染的要求. 实验中采用的知识图谱构建及存储工具为 Neo4j 图数据库, 如图 5 所示.




图5 城市环境知识图谱

Fig. 5 Knowledge graph of urban environments

仿真场景搭建: 基于 Protégé 和 Neo4j 构建静态知识图谱, 利用 CARLA 平台获取动态数据构建动态知识图谱, 并融合生成行为决策指令. 为验证所提出的基于知识图谱的智能决策方法, 本实验搭建了一个典型的城市交通场景——十字路口动态交通环境. 十字路口场景由 CARLA 内置的城市地图提供, 道路为双向两车道, 且各个方向均设置了标准交通信号灯. 实验中, 自车配备了摄像头、激光雷达以及 GPS 传感器, 以实时采集环境数据.

5.1.2 实验设计

在十字路口的每个方向上, 利用 CARLTrafficManager 随机放置一些车辆 (每个方向 3~5 辆车) 且车辆的初始速度与驾驶行为是随机的, 来模拟实时道路中的交通情况. 基于知识图谱规则推理引擎, 按照预置的决策规则进行实时的推理决策并进行规则的指令输出, 利用 CARLA 平台的仿真车辆执行决策指令, 通过记录与专家决策的对比, 验证系统决策生成的正确性与有效性.

5.1.3 实验结果与分析

① 决策准确性分析: 在 30 轮实验测试中, 自车

能够严格按照知识图谱决策规则执行停车、通行和避障等操作, 未出现违章行驶或碰撞现象, 决策准确率达到 95%, 决策准确率对比如图 6 所示. 证明了知识图谱驱动的规则推理方法的可靠性.




图 6 决策准确性对比

Fig. 6 Comparison of decision accuracy

② 实时性评估: 实验数据如图 7 所示, 系统的平均决策响应时间在 60 ms 以内, 满足自动驾驶对实时性的高标准要求. 即使在复杂交通场景下, 通过知识更新与规则推理优化, 决策延迟也保持在可控范围内.




图 7 决策实时性

Fig. 7 Real-time decision-making

在 CARLA 仿真环境中构建十字交叉道路动态车流量场景, 验证了本文提出的基于知识图谱的智能决策方法的有效性. 实验结果证明, 基于动态与静态融合的知识图谱技术能有效地完成交叉道路动态复杂环境下车辆智能行为决策, 有很好的实时性和准确性, 证明了该方法在实际应用中的可行性.

5.2 实车试验验证

实车试验的目的是验证知识图谱与大模型结合方法在越野战场环境中的应用效果, 重点关注方法的优越性和决策准确性.

5.2.1 实验环境与设计

在怀来某测试场开展了实车实验, 实验所在环境为开阔的越野场地. 采用的测试平台为无人轻型卡车, 用于验证所提出的决策系统能否在越野场景进行准确的行为决策. 无人轻型卡车环境感知模块由 4 个激光雷达、1 个固态激光雷达、2 个惯导、4 个

摄像头组成, 能够实时感知周围环境, 并通过局域网 (延时只有 50 ~ 200 μ s, 对无人系统的影响很小) 将感知结果传输至行为决策子系统.

实验数据库方面, 针对越野实验场景所构建的知识图谱包含 52 个节点和 102 个边, 基于 Neo4j 的存储和可视化如图 8 所示. 图例展示了节点的类型, 包括障碍物、路面起伏度、天气信息、通信信号强度等信息.




图 8 越野环境知识图谱

Fig. 8 Knowledge graph of off-road environments

具体实验场景设计为 2 个突发障碍物场景, 其一为凸台障碍, 其二为壕沟障碍, 如图 9 所示. 实验中障碍物检测由车辆的感知模块完成, 并将感知结果发送给行为决策模块. 行为决策模块采用大模型与知识图谱结合的方案, 输出具体的行为决策指令.



图 9 凸台壕沟障碍

Fig. 9 Embankment trench obstacle

具体实施过程中, 利用前期构建的领域知识图谱, 精确表达战场环境状态、任务指令和无人平台的实时状态信息. 这些信息作为结构化输入提供给大模型, 大模型则依托其强大的语言理解、知识推理和策略生成能力进行推理, 生成切合实际需求的具体行为指令. 在真实模拟的越野战场环境中, 无人卡车根据前述大模型输出的行为决策指令进行任务执行.

5.2.2 实验结果与分析

决策系统接收环境和车辆信息, 提取关键词, 查询知识图谱, 并将结果以三元组形式输入大模型. 大

模型通过推理生成决策指令,指导车辆行为.为确保准确性,软件反复试验并记录数据,与专家决策对比分析.图 10 和图 11 展示了突发障碍物情况下的决策指令生成过程.



图 10 知识图谱检索结果




图 11 决策指令生成

Fig. 11 Generation of decision-making instructions

通过结果可以分析得到,此系统可以针对环境生成有效的决策指令.并且知识图谱有效提升了无人车对环境的语义理解能力,而大模型则充分发挥了其强大的推理和决策能力,两者融合后整体决策的鲁棒性与自适应性明显增强.这一系列数据均证明了知识图谱与大模型结合方法在越野环境实车应

用中的优越性与准确性.

5.3 消融实验验证分析

为验证“知识图谱增强型大模型推理策略”的有效性,本文设计了基于 3 种推理方式的消融实验,分析各模块在战术语境问答任务中的贡献,并评估其对回答质量的提升效果.通过拆解系统为不同功能组合的实验子系统,并与整合系统进行定量对比,揭示不同机制对系统性能的影响.实验设置了 3 种对比模型,如表 1.

为确保评价的客观性与专业性,本文选取 100 条由人工标注的高质量问答对作为验证集,涵盖地形判断、障碍应对、战场机动、电磁策略等典型战术推理任务.每条问答对包含标准问题、专家答案与判分标准,覆盖多种复杂组合关系.实验评估从以下 3 个维度展开.

① 准确率 (Accuracy).

衡量模型在结论层面给出正确答案的比例,即输出是否与专家标准答案在策略结论上达成一致,公式如下

$$A = \frac{N_{\text{correct}}}{N_{\text{total}}} \times 100\%$$

式中: N_{correct} 为模型输出与专家答案一致的问题数; $N_{\text{total}}=100$ 为验证问答总数(固定为 100).

② 平均语义匹配度 (Semantic Fit).

反映模型语言输出与战术语境是否契合,由 3 位评审对每个答案评分(0~5 分),取平均值,公式如下

$$S = \frac{1}{N_{\text{total}}} \sum_{i=1}^{N_{\text{total}}} \left(\frac{1}{3} \sum_{j=1}^3 S_{ij} \right) / 5$$

式中: S_{ij} 为第 i 条问答在第 j 位评审下的语义得分.总体再取所有样本的平均,得到最终结果.

表 1 3 种模型方案

Tab. 1 Three model schemes

模型结构	方案
LLM-Only(大模型直接回答)	即直接将用户问题输入 Qwen2.5 模型,不提供任何知识图谱或结构提示,仅依赖语言模型的预训练知识与生成能力进行回答
KG-Only(图谱规则驱动)	仅使用 Neo4j 中的三元组结构进行实体匹配与策略输出,采用模板化回答规则,无语言模型参与
KG+LLM(本系统)	即本研究提出的完整路径,包括关键词引导→图谱检索→思维链构造→本地大模型推理,在思维链辅助下由模型生成决策建议

③ 策略合理性通过率 (Tactical Soundness).

衡量模型输出是否包含符合战术逻辑的策略建议,由专家标注为“通过”或“不通过”,公式如下

$$T = \frac{N_{\text{pass}}}{N_{\text{total}}} \times 100\%$$

式中: N_{pass} 为模型回答被专家组判定为“策略合理”的样本数; $N_{\text{total}}=100$ 为验证问答总数.

表 2 展示了 3 种系统在 100 条验证问答集上的平均性能结果对比.

实验显示,LLM 单独使用时语言表达灵活,但缺

表 2 3 种模型对比实验结果

Tab. 2 Comparison of experimental results of three models

模型结构	准确率/%	语义匹配得分 (0 ~ 5)	策略合理性通过率/%
LLM-Only	61.0	3.02	65.0
KG-Only	68.0	2.41	70.0
KG+LLM	85.0	4.12	90.0

乏结构知识易导致语义漂移, 尤其在高结构约束任务中表现不稳定; KG-Only 结构在准确性与稳定性上占优, 但回答缺乏上下文适应性与自然语言表达. 本系统(KG+LLM)结合知识图谱与大模型, 提升了回答策略合理性与准确性, 同时保持了语言生成的一致性和自然性, 展现出性能优势.

从策略合理性角度看, KG-Only 模式在多目标或模糊条件下难以跨三元组联想; 而 KG+LLM 模式通过链式思维提升策略生成的逻辑连贯性, 并通过中间思维链输出增加了推理过程的透明度和验证性, 为模型输出的可解释性打下基础.

6 结 论

本文提出了一种融合知识图谱与大语言模型(LLM)的智能车辆行为决策系统, 借助 CARLA 仿真平台采集动态环境数据, 构建包含静态与动态信息的综合知识图谱, 并结合大模型的语言理解与推理能力, 实现了面向复杂交通场景的智能行为决策机制. 实验结果表明, 该系统具备良好的实时性与泛化能力, 在仿真与实车环境中均实现了超过 95% 的决策准确率和小于 60 ms 的响应延迟, 验证了其有效性与实用性. 本文的研究不仅提升了知识图谱的动态表达能力, 也扩展了大模型在决策推理领域的应用边界.

参考文献:

- [1] 张天成, 田雪, 孙相会, 等. 知识图谱嵌入技术研究综述[J]. 软件学报, 2023, 34(1): 277 – 311.
ZHANG Tiancheng, TIAN Xue, SUN Xianghui, et al. A review of knowledge graph embedding technology[J]. Journal of Software, 2023, 34(1): 277 – 311. (in Chinese)
- [2] 王昊奋, 丁军, 胡芳槐, 等. 大规模企业级知识图谱实践综述[J]. 计算机工程, 2020, 46(7): 1 – 13.
WANG Haofen, DING Jun, HU Fanghui, et al. A review of large-scale enterprise knowledge graph practice[J]. Computer Engineering, 2020, 46(7): 1 – 13. (in Chinese)
- [3] 吴炎泉. 基于知识图谱的交通案件成因分析[J]. 中国科技信息, 2023(18): 138 – 140.

WU Yanquan. Analysis of causes of traffic cases based on knowledge graph[J]. China Science and Technology Information, 2023(18): 138 – 140. (in Chinese)

- [4] 王帅. 基于领域知识图谱的无人战车智能规划技术研究[D]. 长沙: 国防科技大学, 2019.
WANG Shuai. Research on intelligent planning technology of unmanned combat vehicles based on domain knowledge graph[D]. Changsha: National University of Defense Technology, 2019. (in Chinese)
- [5] 冯拓宇, 李伟平, 郭庆浪, 等. 大语言模型增强的知识图谱问答研究进展综述[J]. 计算机科学与探索, 2024, 18(11): 2887 – 2900.
FENG Tuoyu, LI Weiping, GUO Qinglang, et al. Research progress on knowledge graph question answering enhanced by large language model[J]. Computer Science and Exploration, 2024, 18(11): 2887 – 2900. (in Chinese)
- [6] 赵鑫, 窦志成, 文继荣. 大语言模型时代下的信息检索研究发展趋势[J]. 中国科学基金, 2023, 37(5): 786 – 792.
ZHAO Xin, DOU Zhicheng, WEN Jirong. Research trends of information retrieval in the era of large language model[J]. Chinese Science Fund, 2023, 37(5): 786 – 792. (in Chinese)
- [7] 张才科, 李小龙, 郑胜, 等. 基于大语言模型的知识图谱构建及应用研究[J]. 计算机科学与探索, 2024, 18(10): 2656 – 2667.
ZHANG Caike, LI Xiaolong, ZHENG Sheng, et al. Knowledge graph construction and application based on large language model[J]. Computer Science and Exploration, 2024, 18(10): 2656 – 2667. (in Chinese)
- [8] 汪天翔. 时序知识图谱的嵌入表示模型研究[D]. 长沙: 国防科技大学, 2021.
WANG Tianxiang. Research on the embedded representation model of temporal knowledge graph[D]. Changsha: National University of Defense Technology, 2021. (in Chinese)
- [9] 虞松涛. 基于学术知识图谱的语义检索研究[D]. 武汉: 华中师范大学, 2020.
YU Songtao. Semantic retrieval based on academic knowledge graph[D]. Wuhan: Central China Normal University, 2020. (in Chinese)
- [10] 陈雅茜, 邢雪枫. 基于本体建模的动态知识图谱构建技术研究[J]. 西南民族大学学报(自然科学版), 2021, 47(3): 310 – 316.
CHEN Yaxi, XING Xuefeng. Research on dynamic knowledge graph construction technology based on ontology modeling[J]. Journal of Southwest University for Nationalities (Natural Science Edition), 2021, 47(3): 310 – 316. (in Chinese)
- [11] 牛园园. 基于知识图谱嵌入的多跳问答方法研究[D]. 重庆: 重庆工商大学, 2023.
NIU Yuanyuan. Research on multi-hop question answering method based on knowledge graph embedding[D]. Chongqing: Chongqing Technology and Business University, 2023. (in Chinese)

(责任编辑: 李兵)