



论生成式人工智能的法律风险与治理路径

宋华健

Legal Risks and Governance Path of Generative Artificial Intelligence

SONG Huajian

在线阅读 View online: <https://doi.org/10.15918/j.jbitss1009-3370.2023.1621>

您可能感兴趣的其他文章

Articles you may be interested in

认识论视域下人工智能著作权主体适格性分析

An Analysis of the Copyright Subject Suitability of Artificial Intelligence in the View of Epistemology

北京理工大学学报(社会科学版). 2019(4): 145 <https://doi.org/10.15918/j.jbitss1009-3370.2019.1106>

“零污染”村庄的参与式治理路径与实现机制

Participatory Governance Path and Realization Mechanism of “Zero Pollution” Villages

北京理工大学学报(社会科学版). 2021, 23(6): 41 <https://doi.org/10.15918/j.jbitss1009-3370.2021.7113>

主体交流异化与现代性迷失

Subject Communication Alienation and Modern Loss

北京理工大学学报(社会科学版). 2021, 23(2): 173 <https://doi.org/10.15918/j.jbitss1009-3370.2021.2484>

技术路径嵌入: 邻避运动治理反思与路径拓展

The Embedding of Technological Path: Reflection and Reconstruction of the NIMBY Movement Governance

北京理工大学学报(社会科学版). 2018(1): 25 <https://doi.org/10.15918/j.jbitss1009-3370.2018.3841>

地方政府公共服务创新实践的发展与生成逻辑

The Development and Generation Logic of Local Government Public Service Innovation Practice

北京理工大学学报(社会科学版). 2019(6): 63 <https://doi.org/10.15918/j.jbitss1009-3370.2019.3539>

基于多属性羊群行为的股票风险及其传染

The Study of Stock Risk and Its Contagion—Based on Multi-attribute Herding Behavior

北京理工大学学报(社会科学版). 2017(1): 64 <https://doi.org/10.15918/j.jbitss1009-3370.2017.0109>



关注微信公众号, 获得更多资讯信息

DOI: 10.15918/j.jbitss1009-3370.2023.1621

论生成式人工智能的法律风险与治理路径

宋华健

(华东政法大学 经济法学院, 上海 200042)

摘要: 以 ChatGPT 为代表的生成式人工智能在优化产业结构促进经济发展的同时也带来新的法律风险。语言模型训练中的风险主要包括侵害个人信息与作品著作权风险, 内容生成过程中的风险则体现为人工智能“幻觉”导致的错误信息风险、算法偏见风险、“涌现”导致的算法失控风险以及人机互动中的算法滥用风险。《生成式人工智能服务管理暂行办法》提供基本的治理框架, 但部分条款设置与具体治理方式上存在不足。生成式人工智能的性能取决于训练数据集的规模与质量, 模型训练中的数据治理需要尊重其技术逻辑, 实践中应拓展公共数据中著作权数据与个人数据的合理使用边界。内容治理可以借鉴“宪法人工智能”的基本理念, 构建动态的内容反馈评估机制。

关键词: 生成式人工智能; 风险治理; 合理使用; 宪法人工智能

中图分类号: DF37; DF523.9

文献标志码: A

文章编号: 1009-3370(2024)03-0134-10

“强大人工智能崛起将是人类有史以来最好或最坏的事情, 我们还无法预知是哪一种”。在 2017 年全球移动互联网大会 (Global Mobile Internet Conference, GMIC) 上, 霍金 (Hawking) 在视频演讲中表达了对人工智能快速发展所产生的忧虑。2021 年, ChatGPT-3 作为一种大型语言计算模型开始获得大量关注。相较于现有人工智能, ChatGPT-3 在参数规模、建模能力以及多任务语言协同处理方面都展现出更为优异的性能, 因此被美国麻省理工学院的科技评论杂志评选为年度十大突破技术^[1]。在具体应用当中, ChatGPT 可以从大数量级的资料中快速提取信息从而简化机械或重复性的文本生成工作, 对社会生产力的提升有着潜在的积极影响。因其展现出的无与伦比的应用潜力, 基辛格 (Kissinger) 等人认为“ChatGPT 等生成式人工智能发展预示着一场新的智力革命”^[2]。

智能化技术在优化产业结构促进经济发展的同时也给普通大众带来隐私保护、数据控制、知识产权以及道德伦理等新类型的风险。与侧重分析与判断的决策式人工智能不同, 以 ChatGPT 为代表的生成式人工智能本质上是通过数字内容拆解、大语言模型训练来生成多样化的新内容。其中模型训练中针对著作权内容的使用就存在争议。乔姆斯基 (Chomsky) 言辞激烈地指责 ChatGPT 从海量数据中分析提炼规律并按照底层规则将数据串联在一起形成文章内容的方式是一种“高科技剽窃”。除此之外, 大语言模型的迭代演化也充满不确定性。OpenAI 发布的 GPT 技术报告就显示更为复杂的语言模型引入可以提升 ChatGPT 的能力, 但同时也会带来不可预见的连锁反应与后果。出于对生成式人工智能发展过程中不可控的担忧, 生命未来研究所向全社会发出“暂停大型人工智能研究”的呼吁, 该呼吁获得许多知名科学家与相关从业者支持。在这份公开信中一个凝聚着多方共识的观点是监管部门应大力加快生成式人工智能治理系统的发展, 完善新发展模式下生成式人工智能的监管框架^[3]。中国网信办等七部委在 2023 年 7 月 13 日联合发布全球首个针对生成式人工智能的法规《生成式人工智能服务管理暂行办法》(以下简称《暂行办法》)。《暂行办法》为生成式人工智能发展构建整体监管框架, 但部分条款设置与具体治理模式存在不足之处。

收稿日期: 2023-10-30

基金项目: 国家社科基金青年项目“平台经济发展的税法规制研究”(22CFX031); 上海市浦江人才计划课题“数字金融的监管与国际治理”(21PJJC046)

作者简介: 宋华健 (1994—), 男, 博士研究生, E-mail: 395992018@qq.com

一、生成式人工智能的技术祛魅

“技术变革通常像上帝一样隐晦不明, 尽管人们对其讨论颇多, 但是却鲜有人能够真正理解”^[4]。人工智能自 1956 年达特茅斯会议上被提出以来在实践中经历了逻辑推理、专家系统以及深度学习等模式的变革与演化。人工智能发展的不同阶段对应着截然不同的算法运行范式, 只有充分理解技术发展变革背后的内在逻辑才能针对性地提出严谨、正确的治理思路。

(一) 技术的源起与发展

自 20 世纪中旬图灵测试被提出来, 人工智能领域的专家学者就开始提升算法模型智能化理解通用语言方面能力的尝试。传统语言模型的训练需要结构化的数据来建立模型并处理, 该方法限制了模型在未经精细标注的数据集上的应用。此外, 通过长短时记忆模型来实现的建模结构既无法对周围的词赋予更高的价值, 也无法将输入数据作为一个整体的语料库进行处理, 因此语言模型整体的训练速度有限。从本质上看, 语言模型的文本处理能力通常由三个因素决定: 计算量、模型参数的数量和训练数据集的大小。生成式人工智能的迅速发展得益于更广泛、更多样化的数据集、更高效的算法和更强大实用的计算机硬件。ChatGPT 的底层架构是由 OpenAI 开发的基于自然语言处理 (Natural Language Processing, NLP)^① 技术的大型语言模型 (Large Language Models, LLM)。LLM 通过学习与分析大规模的语言数据来建立对自然语言的理解和生成能力。自然语言处理包括情感分析、问题回答、文本摘要、文本分类、文本生成等流程。GPT 是生成式预训练转化器 (Generative Pre-trained Transformer) 的缩写, 其中自回归转换器 (Transformer) 架构是一种基于自注意力机制的神经网络模型。与传统的数据处理方式不同, GPT 提出“自监督 (semi-supervised)”的模型训练方法, 即先在没有标号的数据上训练一个预训练模型, 再在少量标号数据上训练一个区别的微调模型, 这样处理使算法开始直接处理自然形式的数据, 大大提升了模型整体训练的效率。

(二) 内容生成的逻辑解构

从宏观视角来看, ChatGPT 的运行可以分为模型训练和内容输出两个阶段。大语言模型训练是 ChatGPT 具备强大对话能力的基础, 而 ChatGPT 的内容输出是指底层算法根据输入文本和预先学习的语言模型, 生成符合语言规则的新文本的过程。

从技术维度进行拆解, 大语言模型训练包括数据收集、数据预处理以及构建数据集等环节。首先, 模型训练需要大量的自然语言数据, 因此要搭建一个训练数据库。这些数据大多从互联网、电子书、报纸杂志等多个来源中进行收集。从官方公布的数据来看, GPT-3 模型是建立在一个具有 1 750 亿个参数的语言模型上的最新扩展应用。其次, 在进行训练之前需要将这些数据进行预处理, 预处理通常包括对数据进行标记化、分词、去噪和对齐等操作, 以便将文本转化为计算机可处理的形式。最后, 在训练过程中 ChatGPT 会将大量的语言数据输入到模型中, 并且通过反向传播算法来更新网络参数, 以最小化语言模型在生成文本时的误差。

在消化指数级数据后, 大语言模型已经具备强大的内容反馈能力, 但还没有达到真正定义上通用人工智能的智能化水准。从内容生成视角来看, ChatGPT 的内容反馈并非是类智慧体的逻辑思考, 本质上是大语言模型基于文字排列概率预测的涌现创造。根据 2018 年 OpenAI 发布的原始论文《通过生成式预训练提高语言理解能力 (Improving Language Understanding by Generative Pre-Training)》, 从用户输入提示词到内容生成, 整个过程会包括输入文本解析、输出文本、交互反馈迭代等步骤^[5]。输入文本的解析本质上是将用户输入的自然语言文本转化为模型可处理的向量表示的过程, 这是技术模型实现对话理解的关键。ChatGPT 采用的输入文本解析方法是基于自然语言处理的分词与向量化技术。在将单词转化为向量表示之后, ChatGPT 会对整个输入文本进行上下文建模, 以捕捉输入文本中的语义和逻辑关系。文本

^① NLP 是计算机科学的一个重要研究领域之一, 其主要目的在于创建一个计算机处理系统, 使其能够理解人类的语音或书面的文本输入。NLP 结合了许多技术、算法和模型。它可以使用计算语言学、机器学习、深度学习模型和人工智能应用。从技术层面来看, NLP 通过词义消歧、关联解析、情感分析以及自然语言生成等步骤将结构化信息转化为预言实现人与机器之间的交流。而聊天机器人本质上就是使用 NLP 来响应用户提出的询问, 同时将其映射到系统中可用的最佳响应集。

生成主要是基于随机采样的技术,即从模型输出的概率分布中,随机选择一个概率较高的词作为当前位置的输出,并将其作为下一步的输入。这个过程中,ChatGPT会对模型输出的概率分布进行采样,以得到新的词汇。进行随机采样之后,ChatGPT会根据当前生成的词汇,更新模型状态,并继续进行文本生成,直至达到指定的生成长度或者生成结束符号。在生成文本之后,ChatGPT会对生成的文本进行解码,并输出给用户。在输出回复之后,ChatGPT会接收用户反馈,包括用户对回复的满意度、对话的进展等信息。这些反馈可以被用于对模型进行调整和改进,以提高对话的质量和准确性。

二、生成式人工智能的法律风险

人类的发展历史表明,每一次巨大的技术突破都会带来变革性的制度变迁与范式转型,同时也会产生新的法律风险。法律必须对此做出回应与调整。与以往的技术变革相比,生成式人工智能的技术迭代更为迅速、普及范围更加广泛、对个体的主体性影响也更为深远,因此分析其潜在风险的需求也变得更加迫切。

(一)大语言模型训练中的法律风险:个人信息与著作权保护

从内容生成的流程来看,ChatGPT语言模型训练需要吸收巨量的文本数据。根据OpenAI官网的披露,ChatGPT的训练数据既包括自身训练数据库中的数据,也包括与用户交互过程中用户的输入数据,其中训练库中数据大多是从互联网公开渠道爬取获得,这不可避免地会与现行数据保护的法律法规产生冲突。

首先,涉及个人信息的使用。无论是欧盟的《通用数据保护条例》(以下简称“GDPR”)还是中国的《个人信息保护法》都对此存在严格的限制。《个人信息保护法》第13条规定处理个人信息的7种情形,除去信息主体明确同意的前置性条件之外其余均为严格的法定豁免情形。从生成式人工智能模型训练所需要的数据量级来看,严格遵循知情同意的合规要求几乎无法实现。《个人信息保护法》在第27条针对已公开的个人信息放松针对处理者的合规义务,但是“在合理的范围内”以及“对个人权益有重大影响”的边界依旧需要在实践中进一步明确。根据OpenAI官网的表述,若用户不同意其输入的信息内容作为训练数据,可以根据《使用条款》的相关规定,通过邮件发送的方式进行拒绝授权^[6]。从具体的文本表述上来看OpenAI似乎在用户输入信息的使用中采取了一种选择退出的机制,但是实际上若用户输入信息中包含个人信息,默认的选择退出机制不符合大部分地区个人信息保护相关法规中的知情同意要求。

其次,生成式人工智能对相关受著作权保护作品数据的使用会消解该作品潜在的著作权价值。著作权作为一项法定权利,本质上是为了激励内容创作与知识传播,平衡权利人与社会公众之间的利益,在社会公有领域中为著作权人划出的一块保护区^[7]。但是从著作权法的基本规定来看,针对著作权人的保护能否延伸到生成式人工智能的模型训练行为存在争议。近期美国新闻(媒体)联盟(The News/Media Alliance,以下简称NMA)在发布的声明中就提到ChatGPT等生成式人工智能对传统出版行业的挑战,该声明认为“与传统的搜索引擎不同,生成式人工智能是数据训练的产物,训练数据中包括许多在网上公开但是拥有著作权的作品,直接的内容生成并不会增加原本著作产品的点击量,甚至会取代原本著作内容发布者与消费者之间的关系”^[8]。2023年7月18日,美国作家协会的9000多名作者联合签署了一封致OpenAI等人工智能巨头的公开信。公开信中强调生成式人工智能技术在很大程度上依赖于既有创作者的语言、故事、风格和思想,数以百万计的受版权保护的书籍、文章、散文和诗歌是人工智能系统底层大语言模型的训练基础,但创作者却没有因为他们的贡献而得到任何补偿^[9]。因此,站在创作者的角度,生成式人工智能产生的最大问题在于会剥夺内容创作者在整个价值链上的利益分配,消解该作品潜在的著作权价值。

(二)生成内容中的法律风险:错误、偏见与滥用

自然科学领域发现的真理之所以被公众认可与接受本质上是源于实验结果的可复现性,即自然科学实验过程中的每一个步骤都可以被不同的研究团队所重复,并且得出一样的最终结论。生成式人工智能

的发展拓宽人类解决问题的渠道,但是却无法促进人类的理解。因为人对信息的甄别与建构通常是一种跳跃的思维过程,而 ChatGPT 的出现抹除了这一过程。由于生成内容不是经推理产生的,其本身的正确性很难得到保证,从而导致多种法律风险。

首先, ChatGPT 输出的内容存在内容错误的误导风险。根据实践,在 ChatGPT 模型中就相同问题进行差异化表述,模型的输出结果会存在明显的差异,而在提示词的调整过程中甚至会出现看似相关实际上完全是编造的答案。这也间接证明生成式人工智能中文本生成结果的可信度是有条件的,并且经常受到上下文的限制。如果可信结果的前提预设条件消失,输出内容的可信程度就会发生偏移,甚至会言之凿凿地提供虚假信息。例如,在 ChatGPT 面世不久后,英国《卫报》就发现许多《卫报》记者署名发表的文章本质上是由 ChatGPT 虚构的。总结 ChatGPT 文本生成的基本逻辑可以得出, ChatGPT 对用户问题的响应并不是一种推理式思考,本质上是根据它在训练数据集中“学到”的人类创作的单词组合模式以及序列来生成类似的文本,也就是通过大规模文本语料库的单词序列的导出概率来确定接下来应该出现的单词序列。当语言模型根据自己的内在逻辑而非真实的上下文来生成文本时,就会产生“人工智能幻觉 (AI Hallucinations)”。在技术维度,这一现象通常被认为是大型语言模型针对输入文本展示出的自信但不合理和未经验证的欺骗性反应^[10]。

其次,生成内容中也存在潜在的算法偏见风险。根据图灵研究所给出的定义,“算法偏见 (Algorithmic Bias)”本质上是指由于算法计算过程或算法实施方式的问题而引起的不公平,产生的直接后果是算法对一组用户不适当地给予特权或使另一组用户处于不利地位^[11]。在大语言模型中,算法偏见一般是由训练算法的数据偏差造成的。边缘化群体在训练数据中的代表性往往较低,他们受到嵌入训练数据中潜在社会偏见的影响会更为明显。ChatGPT 从互联网中爬取的数据中不可避免地会存在充满偏见的数据类型,获取训练数据的来源和方法也可能会扭曲输出结果。

此外,大语言模型参数的持续扩大会出现“涌现”现象导致的算法失控风险。回顾技术发展的历史,尽管模型训练效率的迭代提升是生成式人工智能兴起的内因,语言模型的进一步扩展也被证明可广泛地提升在下游任务上的性能和样本处理效率,但是系统中的定量变化(如扩大语言模型)同时也会导致模型产生无法解释的行为,这一现象被称为“涌现 (Emergence)”。这一轮技术变革当中生成式人工智能受到大量关注的一个重要原因在于其本身已具备系统科学中所定义的涌现能力^[12]。从计算机科学的视角来看,如果一种能力在较小的模型中不存在,而在较大的模型中存在,那么它就属于涌现。诺贝尔奖获得者菲利普·安德森 (Philip Anderson) 在 1972 年发表的著名论文《更多即不同 (More is Different)》中提及并推广这一概念,在原文中涌现被定义为“当系统中的定量变化导致行为的质变”^[13]。大语言模型中的涌现现象是生成式人工智能具备强大创造能力、重塑创造逻辑的内在原因,但同时也模糊化从文本输入到文本生成的中间业态。根据《牛津哲学指南》的解释“复杂系统内的涌现属性虽然是从表征较简单成分的属性和关系中产生的,但它既不能从这些较低层次的特征中预测出来,也不能被还原成这些特征”。从论述来看,涌现的一个重要特征是“不可解释性”即无法通过任何构成或共存规律从更简单或最简单情形中推导出来^[14]。很显然,大型语言模型的使用有可能进一步降低透明度和问责制,因为数据处理的中间业态几乎无法进行回溯。从监管视角来看,生成式人工智能带来的最大挑战在于错误内容生成的过程几乎无法回溯并且问题解析过程缺乏可解释性。

最后, ChatGPT 作为直接与用户对话的新型人工智能不可避免地会带来算法滥用的风险。在传统的人工智能讨论中,普通用户通常仅被作为分析决策的对象,以 ChatGPT 为代表的生成式人工智能则塑造一种全新的人机互动范式。ChatGPT 并非是为特定的环境或使用条件所创设的,聊天机器人的信息反馈模式大大降低用户体验人工智能的准入门槛,这也是其迅速积累起前所未有用户规模的根本原因^[15]。用户与 ChatGPT 之间的交互反馈不仅是模型训练的一部分,同时也是其提升正确率、理解率的基础。ChatGPT 会在与用户的交互中进行自我升级与迭代发展,这也意味着它将人工智能的使用升级的权限扩展到具备专业知识的科学团队之外,以组织治理的逻辑来监管 ChatGPT 会变得愈发困难。高度的人机互动性带来全新的法律风险,法律需要延伸其规制的疆域,不仅要约束模型开发者与服务提供者,同时也

要对服务使用者提出新的要求。首先, ChatGPT 展现出来的强大能力会使得用户将越来越多地与它们建立关系, 并逐渐信任它们。用户在与 ChatGPT 互动的过程中可能会被诱导收集个人信息或其他资料, 存在泄露个人信息、商业秘密或国家秘密的风险。基于大语言模型的强大能力, 即使是碎片化不完整的信息, 也有可能被 ChatGPT 进行标签化重组与其他类似数据一起进行深度挖掘, 进而推断出与国家安全、公共安全等相关的情报信息。其次, ChatGPT 存在被用户滥用甚至诱导提供违法信息风险。例如, 在 ChatGPT 发布后不久, 一个开源项目就绕过 OpenAI 设置的安全过滤器诱导其提供大规模独特的、个性化的虚假信息。当公共信息来源充斥着虚假信息时, 公众会逐渐对主流报道失去信任进而导致社会整体出现信任危机。

三、生成式人工智能治理的基本思路

技术创新推动社会经济发展通常以大规模的用户集群为基础, 驱动技术资本与用户之间的联动创新, 形成不断迭代的发展机制, 最终推动社会生产技术与人工智能的共同进化^[16]。根据世界银行《生成式人工智能报告》, 生成式人工智能市场预计在 2026 年增长到 65 亿美元, 复合年增长率为 34.9%^[17]。如何监管生成式人工智能, 监管部门做出的选择将不可避免地带来深远的社会和经济影响。

在考虑人工智能的未来时, 美国选取一条比较包容的监管路径, 强调在新技术被理解甚至被想象之前会保持谦逊与克制。美国监管机构认为在一个透明以及可预测的环境当中人工智能会蓬勃发展, 任何额外规则的施加需要权衡考虑利益与成本。与之相反, 欧盟对于人工智能的监管主体上是基于对新技术发展侵害个体权益担忧, 整体上遵循一种技术怀疑的前置逻辑。2020 年 2 月, 欧盟委员会 (European Commission) 发布《关于人工智能——欧洲追求卓越和信任的方法》白皮书。这份白皮书清晰地传达欧盟监管部门对新人工智能技术的不信任, 其中包含一种迫切的愿望即通过政府控制来遏制可预见和不可预见的危险。根据白皮书, 欧盟委员会似乎正在推进对人工智能应用广泛、横向以及侵入性的监管, 甚至提议进行事前合法性评估, 以控制源自欧盟以外的人工智能应用进入欧盟市场。事实上欧盟在《人工智能法案》的起草过程中也就如何监管生成式人工智能展开了多方争论。欧洲议会人工智能立法伦理领域的顾问认为以 ChatGPT 为代表的生成式人工智能正在以一种全新的方式挑战欧盟现有的监管框架, 其中一个亟需解决的问题在于 ChatGPT 是否应当被认定为是一种“高风险人工智能”^[18]。针对高风险的人工智能, 草案设计严格的全程监管制度, 高风险人工智能在投入使用之前包括整个存续期间内都要受到严格的监管审查。欧盟在人工智能监管上的严厉态度招致许多人工智能创新企业的批评, 立法部门内部就该问题的观点也已开始分化。

事实上, 生成式人工智能发展带来的治理问题是典型的“科林格里奇困境 (Collingridge's Dilemma)”。 “科林格里奇困境”由英国著名的技术哲学家科林格里奇 (Collingridge) 在其著作《技术的社会控制》中提出, 主要观点是“如果在技术形成的早期仅依靠预测对技术过早实施控制, 那么技术很可能就难以爆发。反之, 如果干预过晚又会导致技术成为整个经济社会结构的一部分, 控制成本将会显著提升甚至带来的负面影响无法改变”^[19]。从世界范围内整体治理趋势来看, 人工智能的功能扩张会不可避免地带来新风险, 但已开始有越来越多的观点认为生成式人工智能的监管应当回归比例原则与预防原则^[20]。

(一) 模型训练中的数据治理路径: 合理使用原则的拓展

中国《暂行办法》在第 7 条列举生成式人工智能服务提供者在进行模型训练时应当遵守的基本要求, 具体包括三个方面, 即“不得侵害他人依法享有的知识产权”“涉及个人信息的, 应当取得个人同意或者符合法律、行政法规规定的其他情形”“采取有效措施提高训练数据质量, 增强训练数据的真实性、准确性、客观性、多样性”。指数级规模的训练数据库中涉及数据版权, 同时也涉及个人信息保护等法律风险。如何合理协调技术发展与风险控制是监管框架构建的核心内容。从目前智能化领域发展的基本趋势来看, 生成式人工智能发展的下一个阶段依旧是数据、基础架构、算法、算力、最终模型的快速迭代。ChatGPT 等生成式人工智能本质上依旧是数据驱动的人工智能, 庞大的训练数据规模是人工智能模型生成理想结果的基础。相较于初代的循环神经网络, ChatGPT 底层的 Transformer 架构对数据量有更高

的要求,这也是通用人工智能发展的核心。《暂行办法》的征求意见稿曾对训练数据的质量提出“保证数据的真实性、准确性、客观性、多样性”的刚性要求,似乎是条款引发争议过大,正式出台的《暂行办法》修改了该条款表述。事实上欧盟内部就《人工智能法案》发表具体意见时,大多数成员国针对第17条第3款中“训练、验证和测试数据集应当具有相关性、代表性、正确性和完整性”的表述也提出质疑,许多代表认为从科学视角来看不可能存在完美的没有错误的数据集,该条款规定一个不现实并且很难履行的义务。《暂行办法》这一条款的及时修改符合大语言模型训练的技术逻辑,给生成式人工智能在中国的发展释放巨大的空间,但涉及公开个人信息和著作权数据的训练使用依旧存在争议,亟需进行澄清。

1. 著作权数据的合理使用:非表达性使用的认定

在受著作权保护的作品上训练模型必然涉及对相关作品的复制,在没有明示或暗示许可的情况下,复制受著作权保护的作品用作模型训练数据的合法性取决于是否满足合理使用原则。中国著作权法第24条列举合理使用著作权作品的几种情形,其中第一款是“为个人学习、研究或欣赏”,而这里第一款的表述能否拓展到大语言模型的训练存在争议。从《暂行办法》的具体内容来看,该规定似乎并没有给生成式人工智能模型训练中合理使用著作权保护的数据提供例外的空间^①。模型训练中的数据能否适用版权保护“合理使用”是影响生成式人工智能技术发展的核心问题,拆解这个问题不仅要考虑著作权法的相关规定,同时也要再审视生成式人工智能内容生成的技术逻辑。模型训练、数据输入和结果输出是生成式人工智能运行中的三个不同过程,其中数据输入是模型训练的起点,内容输出是与使用者交互过程中的结果外化。ChatGPT对用户问题的响应本质上是通过大规模文本语料库的单词序列的导出概率来确定接下来应该出现的单词序列,因此模型训练中数据的使用与最终输出结果之间并不存在一一对应的逻辑关联。

从比较法的视野来看,美国版权法在可保护的原始表达和不可保护的事实、思想、抽象和功能要素之间做了根本性的区别,这种区别通常被称为思想-表达二分法。思想与表达的区别意味着,复制有价值的事实和思想,或学习技术、汲取灵感,或模仿版权作品的一般风格都不构成侵权。为体现思想与表达的区别,美国法院一般认为不向新受众传达作者原创表达的技术性复制行为属于合理使用,而这种使用一般被称为非表达性使用。与这些非表达性使用有关的判例法也表明,即使这些使用涉及大量复制,它们也不会干扰版权旨在保护的原始表达的利益。因此,非表达性使用一直被认为是合理使用。美国人工智能领域知名法学学者马修(Matthew)教授在参与美国参议院知识产权司法小组委员会“人工智能与知识产权”听证会时提供的专家证词中明确表达自己的观点。马修认为在受版权保护的作品上训练生成式人工智能应当纳入合理使用范畴,因为它并不属于表达类使用。根据马修的论证,既然法院在处理逆向工程、搜索引擎和剽窃检测软件等技术时,认为这些非表达性使用属于合理使用,那么训练大语言模型也应当同理,因为生成式人工智能并不是为了复制原创而设计的^[21]。事实上日本在2018年的著作权法修订中对待该问题采取更为开放的态度。日本新修订的著作权法专门在第47条第5款第1项规定中新增“通过电子计算机进行信息分析并提供结果”的信息分析服务为新的合理使用情形,这也为人工智能的数据训练设置了合理使用许可^[22]。英国在2022年发布的一份政府咨询回应中明确表态支持将现行《版权、外观设计和专利法》第29条A款规定的合理使用情形扩大到商业用途。欧盟《议会对人工智能法案的谈判立场》也明确提到“为了支持创新,研究活动和免费开源人工智能组件的开发将在很大程度上免于遵守人工智能法案规则”^[23]。从全球的立法趋势来看,松绑人工智能模型训练中的版权限制似乎已经逐渐成为共识,而率先进行制度松绑的法域将毫无疑问地在制度竞争中取得先发优势。中国应当扩大著作权法的合理使用边界,同步修改《暂行办法》中的表述,将人工智能模型训练中的数据使用纳入其中。

2. 公开个人信息的合理使用:卡-梅分析框架下的利益平衡

涉及个人信息的处理,《暂行办法》在宏观层面上规定模型训练中的个人信息处理应当取得个人同意或者符合法律、行政法规规定的其他情形。除此之外,《暂行办法》还就用户的输入信息设定特定的

① 林华. 人工智能数据训练的法律竞争,载金融与数字经济法律研究公众号,2023年8月14日。

保护义务,即“不得收集非必要个人信息,不得非法留存能够识别使用者身份的输入信息和使用记录,不得非法向他人提供使用者的输入信息和使用记录”。事实上,就非公开渠道收集的个人信息纳入模型训练,OpenAI已经给出可供参考的处理方案,即在一对一的服务场景中提供一个知情同意的选择窗口。相反,如何定义用公开渠道获取的个人信息进行模型训练的行为亟需在法律体系中予以明确。知名法学者卡拉布雷西(Calabresi)与其学生梅拉米德(Melamed)提出的卡-梅分析框架(C&M Framework)将不同规则划分为“财产规则”与“责任规则”,两者包含不同的价值立场,前者注重保护已公开个人信息在流通、分析与使用中承载的效率价值与公共利益,后者则强调对信息主体自我决定权的保护^[24]。《个人信息保护法》的第13条第6款和第27条共同组成公开个人信息的处理规则,其中第13条第6款是典型的责任规则设计,允许个人信息处理者无偿处理公开个人信息,第27条则通过对信息主体赋权以及目的限定原则将公开个人信息处理拉回到财产规则的轨道。从立法目的来看,立法在一定程度上放宽信息处理者在处理公开信息上的合规义务,本质上是因为个人信息不仅仅包含人格权属性,同时也蕴含经济或社会价值,据此信息主体对他人的处理负有一定的容忍义务^[25]。从法经济学的视角来看,经济效率与目标分配本质上是决定法益配置与规则选择的主要参数。财产规则与责任规则的使用本质上也体现政策制定者分配偏好,当政策倾向于强化个人数据安全保护时,法律通常会选用财产规则,反之出于促进数据或其他产业发展的目的,责任规则就会变得更加可取^[26]。

实践中,欧盟采取以“财产规则”运用为主的监管路径。在ChatGPT推出后不久,欧洲便率先掀起一股审查浪潮。2023年3月,意大利数据保护机构Garante暂时限制了ChatGPT处理该国用户个人数据的能力,并开始对其涉嫌违反隐私规则的行为进行调查。这一迅速的监管回应实际上是延续了欧盟权利本位的一贯思路。在《通用数据保护条例》(以下简称“GDPR”)立法之初,欧盟委员会考虑数据质量与可追溯性的相关规定,要求非欧盟公司在符合GDPR欧盟要求的数据上训练人工智能应用。在此基础上,欧盟委员会提出信任生态系统(Ecosystem of Trust)监管框架,强调欧盟在人工智能监管上的主要态度是以保护数据主体的基本权利为中心。欧盟委员会希望监管框架既能给公民使用人工智能应用的信心,同时也给公司和公共组织带来人工智能创新时的法律确定性。实际上以“财产规则”为主导的GDPR给在欧洲的人工智能企业带来了沉重的监管负担,GDPR中一个饱受诟病的问题是法规框架减少了对数据共享的激励,并且在很大程度上限制了数据的使用。例如,根据GDPR第5条规定,个人数据的收集应当具备具体、清晰以及正当的目的,对个人数据的处理应当不违背初始目的。这意味着企业在了解拟采集数据的潜在价值之前,不得收集新数据,不得将现有数据用于新目的。然而人工智能领域的许多创新本质上来源于公司合并与处理数据集的能力,生成式人工智能本质上也是在一个庞大数据集上通过自身的算法模型进行不断消化、训练的结果,而在训练之前算法模型的提供方根本无法对可能的训练结果做出预测。GDPR规则与人工智能发展之间的紧张关系在欧盟内部也引发了巨大争论。2020年荷兰国际关系研究所(Clingendael)发布的研究报告也认为GDPR优先考虑个人隐私,牺牲了公司的数据收集,这明显阻碍了创新企业的发展^[27]。总体而言,财产规则与责任规则各有优劣,制度方案的选择应当综合成本、收益以及社会期望。从技术逻辑来看,ChatGPT之所以可以展现出如此强大的对话能力,本质上在于新的算法模型大幅度提升了其本身处理语义数据的能力。但是这种数据处理能力的提升并没有超越机器学习模型的基本逻辑即所有机器学习模型或者是为执行特定任务而训练的人工智能都是在数据集上训练的,数据集的丰富程度决定了模型的能力边界。模型训练中的公开个人信息并不会建立起与信息主体之间一一对应的关系,因此不会侵蚀信息主体的合理隐私期待,若对其施加额外的监管负担会极大地限制信息的流转空间。据此,在生成式人工智能发展初期就公开个人信息的训练使用以《个人信息保护法》第13条第6款的责任规则予以规制较为合适。

(二)生成内容治理的路径矫正:宪法人工智能的制度构造

在传统算法错误导致异常反馈的讨论中,学界提出的最多的主张就是算法透明与算法解释。强调算法透明本质上是希望了解人工智能系统行为的潜在机制,在生成式人工智能的语境下包括对神经网络中的单个神经元进行逆向工程,或分析在输入扰动下输出结果的改变趋势。算法透明是一个理想化的目

标,旨在完全理解系统目标及其思考和行动过程。与算法透明不同,算法解释的要求更为宽松,指的是以人类能够理解的方式解释人工智能系统的行为。《暂行办法》在第19条对生成式人工智能的服务提供者提出了算法解释的基本要求,强调在主管部门开展监督检查时服务提供者应当“按要求对训练数据来源、规模、类型、标注规则、算法机制机理等进行说明”。然而,由于神经网络的不断迭代发展,大语言模型中涌现现象的出现,通过技术逆推寻找错误内容生成原因的手段开始受到诸多限制。在该背景下,《暂行办法》第19条中关于算法解释的相关要求进行严格解释的话会导致服务提供者的合规负担过重,与底层的技术逻辑相悖,因此逐渐变成了一种法律意义上信息披露的客观要求。信息披露虽然可以在一定程度上规范模型开发者的行为,但是无法解决大语言模型本身由于幻觉以及涌现产生的异常内容问题。

事实上,就技术发展过程中遭遇的科林格里奇困境,科林格里奇本人就提出过一个可供参考的思路,即“对于正处于发展中的技术可以尝试调整和改变技术过程中的某些环节来进行控制,对于已经产生负面效应的技术则可以通过改造该技术来克服后果”^[28]。回归大语言模型内容生成的技术逻辑,生成式人工智能的输出内容本身就会通过人类反馈进行模型调整,这通常也被称为“人类反馈强化学习(Reinforcement Learning from Human Feedback, RLHF)”。RLHF通过分析用户或模型测试人员在不同模型输出之间做出的选择来确定评价更高的内容输出并反馈到底层系统对其进行微调,提高后续内容输出的质量与准确率。虽然RLHF在某种程度上确实可以对输出内容进行优化,但是本身存在两个致命缺陷:第一,RLHF的反馈处理效率不高;第二,用户存在奖励不道德以及违法内容的主观动机。为了克服RLHF本身存在的缺陷,人工智能初创公司Anthropic提出宪法人工智能的基本理念与方法。正如著名法学家Lessig就数字化时代法律规则的演化提出的知名论断“代码即法律”,宪法人工智能本质上体现了技术监管的基本思路。简单来说,宪法人工智能是为人工智能系统提供一个内容评价的“章程”,其主要功能在于评估主模型的输出是否遵循了事先确定的章程原则,评估结果被用于优化主模型^[29]。与RLHF相比,宪法人工智能存在优势:(1)提高价值对其的效率,使其从低效的人类监督转向高效的规模化监督;(2)弱化了奖励不道德以及违法内容的主观可能;(3)使模型决策更加透明,从而使人工智能系统的校准信任更加可靠。

实践中宪法人工智能的构建可以分为监督与调整两个阶段。在第一阶段,治理机构可以就旨在生成有害内容的提示词进行总结归类,在此基础上搭建一套智能化系统来随机不间断地与大语言模型进行交流。最初开始训练的大语言模型会生产一些有害的甚至是违法的信息。宪法人工智能会要求模型根据其预设的原则来修正最初的输出内容。通过反复随机测试,第一阶段过后测试方可以获得一个能够识别严重危害信息的预训练模型。第二阶段的调整本质上是将每个提示组合成一个多项选择问题,宪法人工智能根据其内置原则判断哪个回答是最优解,生成一个无害偏好的数据集,并且将其与人类反馈的有益数据集混合在一起进行最终的模型修正。在中国,宪法人工智能的治理思路实际上可以转化成部署一个由监管部门主导,多方共同参与的生成式人工智能评估反馈系统,该系统章程的起草需要充分纳入弱势利益相关者的观点。出于鼓励技术创新的考量,在具体实施时监管部门可以采取渐进式的推进思路,先就重点领域的生成式人工智能进行测试。就生成式人工智能的分级分类,欧盟《人工智能法案》的立法逻辑是将其划分为高风险或者是无风险,而这种归类是从设备提供者的视角出发的,例如法案附录三中所列举的“执法部门”“教育和培训机构”等,人工智能的使用群体及目的决定了该人工智能的风险级别^①。中国《暂行办法》则在第17条就“提供具有舆论属性或者社会动员能力的生成式人工智能服务”做出了应当按照国家有关规定开展安全评估的特别要求。评估反馈系统可以结合上述两种思路,就重点领域生成式人工智能先进行动态持续的交互反馈测试与监管。

① 根据欧盟人工智能法案第6条第1款的规定当满足以下两个条件时,该人工智能系统均被视为高风险:(a)人工智能系统拟用作产品的安全组件,或其本身就是附件二所列的欧盟协调立法所涵盖的产品;(b)安全组件为人工智能系统的产品,或作为产品的人工智能系统本身,需要进行第三方合格评定,以便根据附录II所列的欧盟协调法规将该产品投放市场或投入使用。AI Act Article 6 Chapter 1。

四、结语

智能时代本质上是由人工智能算法与数据共同驱动发展的时代。以 ChatGPT 为代表的生成式人工智能创造了空前的技术应用普及速度,同时也产生了前所未有的风险迭代问题。全球化背景下人工智能领域的治理规则愈发成为制度竞争的重要组成部分。这意味着既需要警惕生成式人工智能对个体权益的侵害,同时也要有客观、包容的心态给予生成式人工智能技术足够的创新发展空间。从发展的视角来看,短期内中国生成式人工智能的发展依旧以基础模型的训练与调试为主,底层技术模型的监管应当秉持审慎包容原则。同时,由于技术发展产生的风险存在典型的“奈特不确定性”,技术领域的立法常常遇到“步伐困境”。未来生成式人工智能服务应用的治理应当是社会各方共同参与,技术治理行业自律先行,在总结经验凝聚共识的基础上建立有效的治理机制。

参考文献:

- [1] MIT Technology Review. 10 Breakthrough technologies 2021[EB/OL]. (2021-02-24) [2023-10-28]. <https://www.technologyreview.com/2021/02/24/1014369/10-breakthrough-technologies-2021>.
- [2] KISSINGER H, SCHMIDT E, HUTTENLOCHER D. ChatGPT heralds an intellectual revolution[J/OL]. Wall Street J, 2023. (2023-02-24) [2023-12-11]. <https://www.wsj.com/articles/chatgpt-heralds-an-intellectual-revolution-enlightenment-artificial-intelligence-homo-technicus-technology-cognition-morality-philosophy-774331c6>.
- [3] Future of Life Institute. Pause giant AI experiments: an open letter[EB/OL]. (2023-03-22) [2023-10-28]. <https://futureoflife.org/open-letter/pause-giant-ai-experiments/>.
- [4] 闫德利. 数字经济: 1776 年以来的又一次变革 [J]. 中国信息化, 2023 (4): 5-7.
- [5] RADFORD A, NARASIMHAN K, SALIMANS T, et al. Improving language understanding by generative pre-training[J/OL]. (2020-09-25) [2023-12-10]. https://cdn.openai.com/research-covers/language-unsupervised/language_understanding_paper.pdf.
- [6] OpenAI. Introducing ChatGPT enterprise[EB/OL]. (2023-08-28) [2023-10-28]. <https://openai.com/blog/introducing-chatgpt-enterprise>.
- [7] 司晓. 奇点来临: ChatGPT 时代的著作权法走向何处: 兼回应相关论点 [J]. 探索与争鸣, 2023 (5): 79-86+178-179.
- [8] New Media Alliance. AI principles[EB/OL]. (2023-04-20) [2023-10-28]. http://www.newsmediaalliance.org/wp-content/uploads/2023/04/FINAL-UPDATED-AI-Principles_4-20-23.pdf.
- [9] Authors Guild. More than 10000 authors sign authors guild letter calling on AI industry leaders to protect writers[EB/OL]. (2023-07-18) [2023-10-28]. <https://authorsguild.org/news/thousands-sign-authors-guild-letter-calling-on-ai-industry-leaders-to-protect-writers/>.
- [10] LI Z. The dark side of ChatGpt: legal and ethical challenges from stochastic parrots and hallucination[J/OL]. arXiv preprint arXiv: 2304.14347, 2023. (2023-02-11) [2023-12-10]. <https://arxiv.org/ftp/arxiv/papers/2304/2304.14347.pdf>.
- [11] Alan Turing Institute. Defining data science and AI[EB/OL]. (2023-04-20) [2023-10-28]. <https://www.turing.ac.uk/news/data-science-and-ai-glossary>.
- [12] FROMM J. Types and forms of emergence[J/OL]. arXiv preprint nlin/0506028 (2005). (2005-06-13) [2023-12-10]. <https://arxiv.org/ftp/nlin/papers/0506/0506028.pdf>.
- [13] ANDERSON P W. More is different: broken symmetry and the nature of the hierarchical structure of science[J]. *Science*, 1972, 177 (4047): 393-396.
- [14] WEI J, TAY Y, BOMMASANI R, et al. Emergent abilities of large language models[J/OL]. arXiv preprint arXiv: 2206.07682, 2022. (2023-06-15) [2023-12-11]. <http://arxiv.org/pdf/2206.07682v1>.
- [15] HELBERGER N, DIAKOPOULOS N. ChatGPT and the AI act[J/OL]. Internet Policy Review, 2023, 12 (1). (2023-02-16) [2023-12-10]. <https://policyreview.info/essay/chatgpt-and-ai-act>.
- [16] 方兴东, 钟祥铭. ChatGPT 革命的理性研判与中国对策: 如何辨析 ChatGPT 的颠覆性变革逻辑和未来趋势 [J]. 西北师大学报(社会科学版), 2023 (4): 23-36.
- [17] World Bank Group. Publication: generative artificial intelligence[R]. Washington: WBG, 2023.
- [18] ANNA F. ChatGPT's rapid entry – urgent for the government to appoint an authority for responsible AI[EB/OL]. (2023-02-06) [2023-10-28]. <https://anch.ai/blog/chatgpts-rapid-entry-urgent-for-the-government-to-appoint-an-authority-for-responsible-ai/>.
- [19] 肖雷波, 柯文. 技术评估中的科林格里奇困境问题 [J]. 科学学研究, 2012, 30 (12): 1789-1794.
- [20] DE MINICO G. Too many rules or zero rules for the ChatGPT?[J]. BioLaw Journal–Rivista di BioDiritto, 2023 (2): 473-483.
- [21] MATTHEW S. Hearing on “artificial intelligence and intellectual property part II: copyright and artificial intelligence”[J/OL]. (2023-07-12) [2023-12-10]. https://www.judiciary.senate.gov/artificial-intelligence-and-intellectual-property_part-ii-copyright.

- [22] 郑重. 日本著作权法柔性合理使用条款及其启示[J]. *知识产权*, 2022(1): 112-130.
- [23] European Parliament. Parliament's negotiating position on the artificial intelligence act[J/OL]. (2023-07-06) [2023-12-10]. [https://www.europarl.europa.eu/RegData/etudes/ATAG/2023/747926/EPRS_ATA\(2023\)747926_EN.pdf](https://www.europarl.europa.eu/RegData/etudes/ATAG/2023/747926/EPRS_ATA(2023)747926_EN.pdf).
- [24] 齐英程. 已公开个人信息处理规则的类型化阐释[J]. *法制与社会发展*, 2022, 28(5): 210-224.
- [25] 解正山. 论已公开个人信息的“合理处理”[J]. *学习与探索*, 2022(9): 69-78+198.
- [26] 丁晓强. 个人数据保护中同意规则的“扬”与“抑”: 卡-梅框架视域下的规则配置研究[J]. *法学评论*, 2020, 38(4): 130-143.
- [27] Clingendael. Europe's digital decade? Navigating the global battle for digital supremacy[R]. Netherlands: Clingendael, 2020.
- [28] 顾益, 陶迎春. 扩展的行动者网络: 解决科林格里奇困境的新路径[J]. *科学学研究*, 2014, 32(7): 982-986.
- [29] BAI Y, KADAVATH S, KUNDU S, et al. Constitutional AI: harmlessness from AI feedback[J/OL]. (arXiv: 2212.08073). arXiv. 2022. (2022-12-15) [2023-12-10]. <https://arxiv.org/abs/2212.08073>.

Legal Risks and Governance Path of Generative Artificial Intelligence

SONG Huajian

(School of Economic Law, East China University of Political Science and Law, Shanghai 200042, China)

Abstract: Generative artificial intelligence (AI), represented by ChatGPT, has brought new legal risks while optimizing industrial structure and promoting economic development. Risks in the training of language models mainly include infringement of personal information and copyrights of works, while risks in the process of content generation are reflected in the risk of misinformation caused by AI “illusion”, the risk of algorithmic bias, the risk of loss of control of algorithms caused by “emergence”, and the risk of algorithmic misuse in the interaction between humans and AI. Although “The Interim Measures for the Management of Generative Artificial Intelligence Services” provides a basic governance framework, there are still deficiencies in the setup of some provisions and the specific governance approach. The performance of generative AI depends on the size and quality of the training dataset, data governance in model training needs to respect its technical logic, and the practice should expand the boundary of reasonable use between public copyrighted data and public personal data. Content governance can draw on the basic concept of “constitutional AI” to build a dynamic content feedback and evaluation mechanism.

Keywords: generative AI; risk governance; rational use; constitutional AI

[责任编辑: 箫姚]